Web Mining
Laboratoire 1

Cédric Campos Carvalho, Elena Najdenovska, Laura Elena Raileanu

Institut des Technologies de l'Information et de la Communication (IICT)

Crawling, indexation et recherche de pages Web

Les points étudiés:

- *Crawling* de pages web
- Construction d'un index avec *ElasticSearch*
- Implémentation d'une fonctionnalité de recherche
- Deux questions théoriques

- A rendre sur *Moodle* avant le **jeudi 12.03.2026 à 23h59**
- Groupes de 2 ou 3 personnes

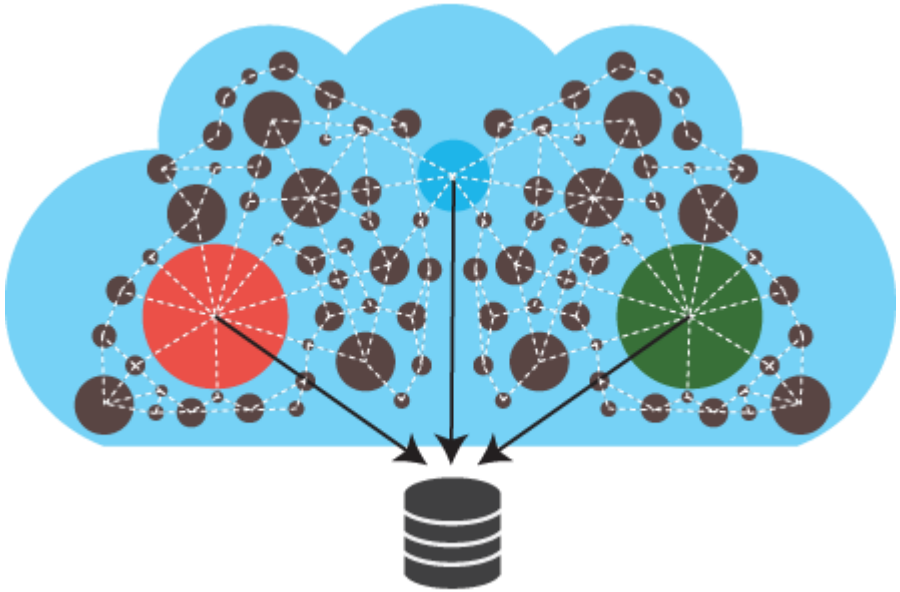

Partie 1
Crawler

- Réalisation d'un logiciel en *Python* utilisant la librairie *Scrapy* pour réaliser un crawler
  - On ne visitera que des formats de fichiers textuels (et avec un certain intérêt)
  - On se limitera à un seul domaine
  - Attention de ne pas se faire «blacklister»

- On souhaite récupérer et indexer spécifiquement des informations sur une page
  - Champs spécifiques
  - Données structurées

-> Selectors de Scrapy

```
import scrapy

class QuotesSpider(scrapy.Spider):
   name = "quotes"

   start_urls = [
      'https://quotes.toscrape.com/page/1/',
      'https://quotes.toscrape.com/page/2/',
   ]

   def parse(self, response):
      print(response.css('title::text').get())
```

Partie 2
Indexation

- Utilisation d'*ElasticSearch* pour l'indexation des champs
  - Plateforme logicielle pour l'indexation et la recherche de données
  - Basée sur la bibliothèque *Apache Lucene*
  - Utilisable à l'aide d'une API basée sur HTTP ou de librairie plus haut niveau
  - Associé à Kibana pour la visualisation des données
- Il vous faudra configurer précisément les champs (ainsi que leur type) que l'on souhaite indexer

Partie 3
Recherche

- Le but de cette partie est d'utiliser l'index que l'on vient de créer pour effectuer des recherches
- Un deuxième programme *Python* mettant en œuvre cette fonctionnalité de recherche
- Cette recherche devra privilégier certains champs par rapport à d'autres et afficher le score des documents retournés

```
Haute École d'ingénierie et de gestion du canton de Vaud
16.27323
https://fr.wikipedia.org/wiki/HEIG-VD

Haute École de gestion du canton de Vaud
15.942445
https://fr.wikipedia.org/wiki/HEG-VD

École d'ingénieurs du canton de Vaud
15.564051
https://fr.wikipedia.org/wiki/EIVD

Haute École spécialisée de Suisse occidentale
15.480998
https://fr.wikipedia.org/wiki/HES-SO
```

Partie 4
Questions théoriques

Deux sujets à développer
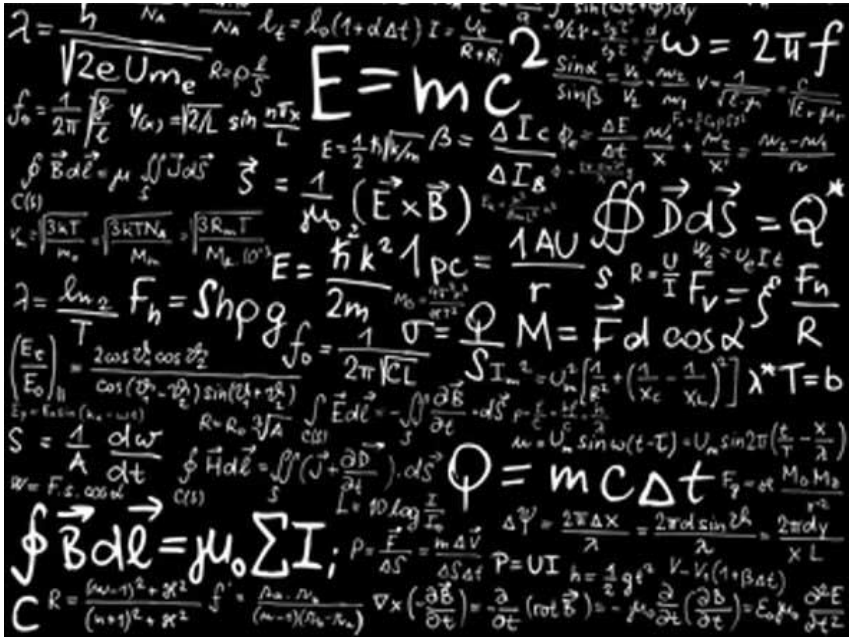
- Indexation multilingue
- Recherche floue
  Fuzzy query